

Data Science – Princípios e Técnicas

Maio
2025



Quem sou eu?

Inteligência Artificial para Jogos Digitais



Prof. Marco Mialaret

Doutorando em Ciência da Computação pelo CIN-UFPE.

Mestre em Matemática pela UFPB.

Licenciado em Matemática pela UFRPE e Tecnólogo em Banco de Dados pelo SENAC.

Inteligência Artificial para Jogos Digitais


Vínculos Atuais:

- Professor Assistente na Faculdade SENAC.

Inteligência Artificial para Jogos Digitais

- **Gerente do projeto Hub do Comércio:** parceria firmada entre a faculdade SENAC e a Fecomércio para a criação de uma plataforma que centraliza dados econômicos e visualizações.

Inteligência Artificial para Jogos Digitais



Inteligência Artificial para Jogos Digitais



Onde me encontrar:

<https://www.linkedin.com/in/marco-mialaret-junior/>

e

<https://github.com/MatmJr>

A disciplina

Data Science



8:00 - Passar o Link

1. Criação do Repositório Git (0h30)

- Introdução ao versionamento com Git
- Criando e conectando repositório local e remoto (GitHub)
- Commits, push/pull e boas práticas de commit

2. Configuração do Ambiente (0h30)

- Instalação do Python (via pip)
- Instalação de bibliotecas (pandas, requests, matplotlib, etc.)
- Organização do workspace (pastas, arquivos, boas práticas)
- Introdução ao Jupyter Notebook

Data Science

3. Introdução ao Pandas (1h00)

- Estruturas principais: Series e DataFrames
- Leitura de arquivos (CSV, Excel)
- Seleção e filtragem de dados
- Operações básicas

10:00 - Intervalo - Passar o Link - Café

Data Science

4. Pré-processamento de Dados (2h)

- Identificação e tratamento de valores ausentes
- Conversão de tipos de dados
- Padronização e transformação de colunas
- Criação de variáveis derivadas

12:00 - Almoço

Data Science

13:00 - Volta ao trabalho com Café

5. Visualização de Dados (1h)

- Gráficos básicos com matplotlib e pandas.plot()
- Gráficos de dispersão, barras, linha e histogramas
- Personalização e boas práticas de visualização

6. Consumo de APIs (1h)

- O que são APIs e onde encontrá-las
- Requisições HTTP com requests
- Consumo de dados em formato JSON
- Carregamento direto para DataFrame

Data Science

15:00 - Intervalo e Mais café

7. Introdução ao Power BI (1h30)

- Importação de dados (arquivo ou API)
- Criação de visualizações simples (gráficos, tabelas)
- Uso de filtros e segmentações
- Publicação e compartilhamento de dashboards

16:30 - Chamada

17:00 - Encerramento

Git & GitHub na nossa disciplina

Data Science

Git é um sistema de controle de versão distribuído que permite aos desenvolvedores rastrear e gerenciar mudanças no código fonte ao longo do tempo. É uma ferramenta essencial para a colaboração em projetos de desenvolvimento de software.

Data Science

GitHub é uma plataforma de hospedagem para repositórios Git que facilita a colaboração entre desenvolvedores. Além de armazenar código, o GitHub oferece ferramentas para revisão de código, gerenciamento de projetos e integração com outras ferramentas de desenvolvimento.

O Python

Banco de Dados

Python foi lançado em 1991 e, desde então, tem marcado a evolução da programação ao oferecer uma sintaxe clara e concisa que permite escrever o mesmo requisito com menos linhas de código.



Banco de Dados

Enquanto muitos programadores se concentram exclusivamente em linguagens como Java e C#, Python demonstrou que a inovação não depende de poucas tecnologias, mas sim da constante criação de linguagens que atendem a propósitos específicos.


Banco de Dados

Inicialmente concebido para facilitar a escrita e a leitura de código, Python rapidamente se expandiu para diversas áreas, como desenvolvimento web, processamento de texto, machine learning e recomendação de conteúdo, acompanhando as demandas e tendências do mercado.

Configurando o Windows

Banco de Dados

Abra a Microsoft Store e busque o Python





Banco de Dados

Depois Instale o Visual Studio Code




Banco de Dados

Após instalar e abrir o VS Code, acesse a aba de extensões.




Banco de Dados

Vá para a aba Explorer e escolha a opção Open Folder.




Banco de Dados

Escolha um local para criar a pasta de trabalho e clique em open




Banco de Dados

Crie um arquivo chamado aula.py



Banco de Dados

Vamos testar se está tudo certo e configurado.



```
EXPLORER
AULA
  aula.py


aula.py
1 print("Primeiro Teste")

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS
Python
PS C:\Users\marco\OneDrive\Área de Trabalho\aula> & C:/Users/marco/AppData/Local/Microsoft/WindowsApps/python3.12.exe "c:/Users/marco/OneDrive/Área de Trabalho/aula/aula.py"
Primeiro Teste
PS C:\Users\marco\OneDrive\Área de Trabalho\aula>
```

Criando o Venv

Data Science


Após criar a pasta chamada DataScience, clicar com o botão do lado direito e selecionar a opção abrir no terminal



```
PS E:\Senac\Aulas\CursoDataScience> code .
```

Banco de Dados

Esta etapa demora um tempo, mas dando tudo certo irá aparecer uma pasta chamada `.venv` no seu diretório.



Banco de Dados

O Venv é uma ferramenta que permite que você configure cada projeto da maneira que for necessário. Isto é, para evitar o famoso:

Mas, na minha máquina funciona!

Banco de Dados


Agora vamos para o canto inferior direito

Clique no local que tem a versão do Python que estamos trabalhando

```
Ln 1, Col 24  Spaces: 4  UTF-8  CRLF  {} Python 3.12.9 64-bit (Microsoft Store)
```

Banco de Dados


Será aberto um menu na parte superior do VS Code



Escolha a opção “Create Virtual Environment...”


Banco de Dados

Selecione a opção Venv



Banco de Dados

E depois o interpretador disponível.



Um pouco de estrutura de dados no Python

Data Science

```
x = 1
y = 0.1324

print("x vale ",x)
print("y vale ",y)
```

Data Science

```
x = "Data "  
y = "Science"  
print(x + y)
```

Data Science

INTEIROS

Em Python 3, números inteiros possuem precisão arbitrária, sem limite fixo de faixa e a ocupação de memória cresce conforme necessário. É possível declarar números inteiros em formatos decimais, octais, hexadecimais e binários.

Data Science

Para octais, adiciona-se um prefixo 0 ao número (ex: 0123), e para hexadecimais, utiliza-se o prefixo 0x ou 0X (ex: 0xFFFFFFFF ou 0X006699).

Data Science

FLOAT

Representa números reais e/ou que possuem sinal de expoente (e ou E). Esses números são comumente chamados de números de ponto flutuante.

Data Science

Por exemplo: 0.00213, .0015, 1.1265 e 3.01e23 (o mesmo que 3.01×10^{23}).

Data Science

BOOL

Os valores do tipo bool representam dois valores: True (igual ao int 1) e False (igual ao int 0).

Data Science

NONE TYPE

NoneType é o tipo de None, uma constante embutida do Python que, assim como True e False, e é frequentemente utilizada para representar a ausência de um valor, similar ao null na linguagem C e derivadas. Exemplo: `a = None` (o mesmo que null em Java).

Data Science

Uma variável do tipo string, basta que coloquemos entre aspas simples, duplas ou triplas

Em Python, tudo é objeto, assim as Strings são objetos que tem embutidos vários métodos.

Data Science

OPERADORES

Aritméticos	Comparação	Lógicos
+	==	and
-	!=	or
*	>	not
/ ou // (parte inteira)	<	
%	>=	
+= -= *= /=	<=	
**	in in not	
is		

Data Science

Podemos fazer conversões para resolver os eventuais problemas com tipagem:

```
a = float(22/5)
b = int(4.5)
c = int(3.9)
d = int(0xff563)
e = float(int(3.9))
f = int(float(3.9))
g = int(float(3))
h = round(3.9)
i = round(3)
j = int(round(3.9))
```


Ciência de Dados, finalmente!

Data Science

“Um cientista de dados é alguém que sabe mais sobre estatística do que um cientista da computação e mais sobre ciência da computação do que um estatístico”


Data Science

A ciência de dados é uma área extremamente variada. Ela engloba desde profissionais que se assemelham à estatísticos até aqueles que são praticamente engenheiros de software. Alguns dominam o aprendizado de máquina, enquanto outros possuem conhecimento limitado sobre o tema.

Data Science

Apesar da diversidade na ciência de dados, podemos tentar definir um cientista de dados como alguém que extrai conhecimento a partir de dados desorganizados.

Data Science



Cientista x Analista x Eng. de Dados

Data Science



Embora possam parecer similares, essas Três áreas têm sim uma diferença entre elas.

A **Ciência de Dados** abrange muitos modelos e métodos científicos, matemáticos e estatísticos, além de ferramentas para analisar e manipular dados.

Data Science

A **Análise de Dados** é mais direcionada e focada em objetivos específicos. Em vez de buscar conexões gerais entre os dados, essa área trabalha com metas diretas e definidas, organizando os dados de maneira que permita extrair informações relevantes para alcançar esses objetivos.

Data Science

Além disso, a análise de dados frequentemente envolve a criação de visualizações que ajudam a comunicar os insights de forma clara e impactante, facilitando a tomada de decisões estratégicas para o sucesso da empresa. Pode ser uma boa porta de entrada na área.

Data Science

A **Engenharia de Dados** é responsável por projetar, construir e manter a infraestrutura necessária para a coleta, preparação e organização dos dados. Esse trabalho cria a base sólida sobre a qual a Ciência de Dados pode atuar, permitindo que os dados sejam analisados de maneira eficiente e precisa para gerar insights valiosos.

E o mercado de trabalho?


Data Science

Segundo a IDC, cerca de 2,5 quintilhões de dados são gerados diariamente. O grande desafio para as empresas é converter essa imensa quantidade de dados brutos em informações valiosas e insights úteis para alcançar objetivos específicos, papel fundamental desempenhado pela Ciência de Dados.


Data Science

Este cenário suscita um interesse crescente em entender o mercado de Ciência de Dados e avaliar o potencial de investimento nessa carreira.

Data Science




LinkedIn search results for "Engenheiro de dados" in Brazil. The search bar shows "Engenheiro de dados" and "Brasil". The results bar displays "Engenheiro de dados em: Brasil" with "764 resultados" and a "Configurar alerta" toggle switch.



LinkedIn search results for "dados" in Brazil. The search bar shows "dados" and "Brasil". The results bar displays "dados em: Brasil" with "2.469 resultados" and a "Configurar alerta" toggle switch.



LinkedIn search results for "Big Data" in Brazil. The results bar displays "Big Data em: Brasil" with "1.492 resultados" and a "Configurar alerta" toggle switch.



LinkedIn search results for "Cientista de dados" in Brazil. The search bar shows "Cientista de dados" and "Brasil". The results bar displays "Cientista de dados em: Brasil" with "963 resultados" and a "Configurar alerta" toggle switch.

Definições importantes

Data Science

Dados:

Coleções de medições, características ou fatos sobre um grupo.

Ciência de dados:

O processo de extrair significado dos dados.

Data Science



Registros:

são o local onde as informações individuais são armazenadas. Cada registro consiste em um ou mais campos. Em um banco de dados é uma linha de uma tabela que armazena informações individuais. Os campos correspondem às colunas da tabela.

Variáveis:

Características particulares, medições ou fatos que compõem um registro.

Data Science

Dados quantitativos:

Dados numéricos. Dados quantitativos podem ser discretos (como o número de pessoas em uma família) ou contínuos (como a média de notas).

Data Science

Exemplos de variáveis quantitativas:

- altura
- peso
- renda anual
- GPA da faculdade

Data Science

Dados qualitativos:

Variáveis qualitativas são geralmente categorias não numéricas às quais os dados podem pertencer (como cor de cabelo). Algumas categorias podem ter uma ordem associada a elas, mas a ordem não implica uma natureza numérica para as categorias. Por exemplo, uma pergunta de pesquisa pode ter respostas que variam de Discordo Fortemente a Concordo Fortemente.

Data Science

Exemplos de variáveis qualitativas:

- cor do cabelo (loiro, castanho, preto, vermelho, cinza, ...)
- status atual da precipitação (sem precipitação, chovendo, nevando, granizando, ...)
- tipo de carro (sedan, coupé, SUV, minivan, ...)

Data Science

Pergunta de pesquisa:

Uma pergunta que pode ser respondida usando pesquisa, incluindo coleta de dados e análise.

Data Science

Por exemplo:

- Mais educação se traduz em mais riqueza?
- O clima está mudando?
- Quão rápido o coronavírus COVID-19 estava se espalhando quando se tornou prevalente nos Brasil dezembro de 2020?

O ciclo de vida de um projeto de Data Science


Data Science

O Ciclo de Vida da Ciência de Dados envolve várias etapas, desde a limpeza de dados até a modelagem e avaliação, para extrair insights e previsões úteis para objetivos comerciais.

As principais etapas são:

Data Science





O pandas

Data Science

Pandas é uma biblioteca open source da linguagem Python, amplamente usada em Ciência de Dados para manipulação e análise de dados. O nome vem de Panel Data, um termo da econometria.



Data Science



Com uma estrutura simples e intuitiva, permite trabalhar com dados tabulares de forma eficiente, sendo ideal para limpeza, tratamento, análise exploratória, integração com machine learning e visualização de dados.

Além disso, se integra facilmente com outras bibliotecas populares como NumPy, Scikit-Learn, Matplotlib e Plotly.

Data Science

Estruturas básicas de dados no Pandas

O Pandas oferece duas estruturas principais para trabalhar com dados:

Séries: é um vetor (array unidimensional) rotulado, que pode armazenar dados de qualquer tipo, como números inteiros, strings ou até objetos do Python.

Data Science

DataFrame: é uma tabela (estrutura bidimensional), parecida com uma planilha do Excel ou uma tabela de banco de dados, composta por linhas e colunas, onde cada coluna é, na verdade, uma `Series`.

Data Science

Exemplo Série: `s = pd.Series([3, 7, 5, np.nan, 6, 8])`

```
import numpy as np
import pandas as pd

s = pd.Series([3, 7, 5, np.nan, 6, 8])
s
```

[76] ✓ 0.0s Open 's' in Data Wrangler

...	0	3.0
	1	7.0
	2	5.0
	3	NaN
	4	6.0
	5	8.0

dtype: float64

Data Science



Principais métodos dessa estrutura de dados:

Métodos de inspeção

- `s.head()` – primeiros valores
- `s.tail()` – últimos valores
- `s.index` – mostra o índice
- `s.values` – mostra os valores como array
- `s.dtype` – tipo dos dados
- `s.shape` – dimensões

Data Science

Métodos de análise

- `s.isnull()` – identifica valores ausentes (NaN)
- `s.notnull()` – identifica valores não ausentes
- `s.count()` – quantidade de valores não nulos
- `s.sum()` – soma dos valores
- `s.mean()`, `s.median()` – média e mediana
- `s.max()`, `s.min()` – valor máximo e mínimo
- `s.describe()` – estatísticas gerais (média, desvio padrão, etc.)

Data Science

Métodos de transformação

- `s.fillna(0)` – preenche valores NaN com 0
- `s.dropna()` – remove valores NaN
- `s.astype(int)` – converte o tipo (ex: para `int`)
- `s.apply(func)` – aplica uma função personalizada
- `s.map({1: "um", 3: "três"})` – substitui valores com dicionário

Data Science

Outros úteis

- `s.unique()` – retorna valores únicos
- `s.value_counts()` – frequência dos valores
- `s.sort_values()` – ordena os dados

Data Science



Uma estrutura de dados importante

DatetimeIndex: é uma estrutura do Pandas que representa uma sequência de datas e horários. Ela funciona como um índice especializado para séries temporais, permitindo operações eficientes como filtragem por data, reamostragem (resampling), agrupamento por período (mês, trimestre, etc.) e alinhamento de dados ao longo do tempo.

Data Science

Criando índices com as datas

Diário

```
pd.date_range("20250101", periods=6)
```

Mensal

```
pd.date_range("20250101", periods=6, freq='MS')
```

Último dia de cada mês

```
pd.date_range("20250101", periods=6, freq='ME')
```

Data Science



Mudando para o padrão brasileiro:

```
dates = pd.date_range(start="2025-01-01", periods=6, freq="MS")
dates_br = dates.strftime("%d/%m/%Y")
print(dates_br)
```

Data Science

Exemplo DataFrame:

```
df = pd.DataFrame(np.random.randint(1, 5, size=(6,4)), index=dates_br, columns=list("ABCD"))
```

	# A	# B	# C	# D
01/01/2025	3	3	1	1
01/02/2025	4	1	3	4
01/03/2025	3	3	4	1
01/04/2025	4	3	4	4
01/05/2025	2	3	1	3
01/06/2025	2	4	4	3

Data Science



Principais métodos dessa estrutura de dados:

Exploração e inspeção

- `df.head()` – mostra as primeiras linhas
- `df.tail()` – mostra as últimas linhas
- `df.shape` – mostra o número de linhas e colunas
- `df.columns` – nomes das colunas
- `df.index` – índice do DataFrame
- `df.dtypes` – tipos dos dados
- `df.info()` – resumo geral (útil para ver nulos e tipos)
- `df.describe()` – estatísticas básicas das colunas numéricas

Data Science

Seleção de dados

- `df['A']` – acessa a coluna A
- `df[['A', 'B']]` – acessa múltiplas colunas
- `df.loc['01/01/2025']` – busca por label no índice
- `df.iloc[0]` – busca por posição numérica

Data Science

Filtragem e operações

- `df[df['A'] > 2]` – filtra linhas com base em condição
- `df.mean()` – média por coluna
- `df.sum()` – soma por coluna
- `df.isnull() / df.dropna() / df.fillna()` – lida com nulos
- `df.apply(func)` – aplica função por coluna
- `df.sort_values(by='B')` – ordena pelo valor de uma coluna

Data Science

Outros úteis

- `df.value_counts()` – frequência de valores (mais comum em Series)
- `df.rename()` – renomeia colunas
- `df.reset_index()` / `df.set_index()` – manipula o índice
- `df.copy()` – cria uma cópia do DataFrame

Carregando Dados em CSV

Data Science

O engenheiro de dados da sua empresa forneceu acesso a dois conjuntos de dados pré-processados. Agora, cabe a você analisá-los cuidadosamente para identificar quais escolas utilizaram seus recursos de forma mais eficiente na preparação de estudantes que se destacaram nas Olimpíadas de Redação e de Matemática.

Data Science

<https://drive.google.com/uc?id=1Jgto7psHaMRTAVzcFt7D6SgJiHMB7uGT>

```
import pandas as pd

url = "https://drive.google.com/uc?id=1Jgto7psHaMRTAVzcFt7D6SgJiHMB7uGT"

escolas = pd.read_csv(url)
```

Data Science



Perguntas motivadoras:

- Quais são os tipos de variáveis presentes no conjunto de dados?
- Existem dados faltantes?
- Existem dados duplicados?

Data Science

- Quais são os tipos de variáveis presentes no conjunto de dados?

```
escolas.info()
```

Data Science

Verificação de dados faltantes:

```
escolas.isnull().sum()
```

```
escolas.isna().sum()
```

Data Science

Verificação de dados duplicados:

```
escolas.duplicated().sum()
```

Data Science

Para encontrar uma descrição dos dados usamos o describe:

```
escolas.describe()
```

✓ 0.0s

	ID_Escola	Numero_Alunos	Orcamento_Anual
count	15.000000	15.000000	1.500000e+01
mean	7.000000	2611.333333	1.643295e+06
std	4.472136	1420.915282	9.347763e+05
min	0.000000	427.000000	2.480870e+05
25%	3.500000	1698.000000	1.046265e+06
50%	7.000000	2283.000000	1.319574e+06
75%	10.500000	3474.000000	2.228999e+06
max	14.000000	4976.000000	3.124928e+06

Data Science

Temos alguns problemas:

- Notação científica pode atrapalhar a interpretação;
- Onde estão as outras variáveis?

Data Science

- Notação científica pode atrapalhar a interpretação;

```
# Ajustar a configuração global para evitar notação científica
pd.set_option('display.float_format', '{:.2f}'.format)

escolas.describe()
```

Data Science

- Onde está o describe das outras variáveis?

```
quantitavas = ['Numero_Alunos', 'Orcamento_Anual']  
qualitativas = ['Nome_Escola', 'Tipo_Escola']
```

```
escolas[quantitavas].describe()
```

```
escolas[qualitativas].describe()
```

Data Science

Link do dataset:

https://drive.google.com/uc?id=15aOJIGAyLMSY1gecjiCgu2ko_rilcKQy

Data Science

estudantes

	ID_Estudante	Nome_Estudante	Genero	Serie	Nome_Escola	Nota_Redacao	Nota_Matematica
0	0	Kevin Bradley	M	6	Escola A	66	79
1	1	Paul Smith	M	9	Escola A	94	61
2	2	John Rodriguez	M	9	Escola A	90	60
3	3	Oliver Scott	M	9	Escola A	67	58
4	4	William Ray	F	6	Escola A	97	84

Data Science

Perguntas:

Existem dados faltantes nas tabelas?

Existe algo em comum nas duas tabelas?

Data Science

Verificação de dados faltantes:

```
escolas.isnull().sum()
```

```
escolas.isna().sum()
```

Repetir o processo para escolas.

Data Science

Combinando os datasets:

```
data = pd.merge(estudantes,  
                 escolas,  
                 how='left',  
                 on=["Nome_Escola", "Nome_Escola"])
```

✓ 0.0s

Data Science

Entendendo as variáveis categóricas:

```
data["Genero"].unique()
```

```
data["Serie"].unique()
```

```
data["Tipo_Escola"].unique()
```

Data Science

Algumas perguntas:

- Qual o orçamento total das escolas?
- Qual a nota média dos alunos nas disciplinas analisadas?

Data Science



Algumas perguntas:

- Qual o orçamento total das escolas?

```
escolas["Orçamento_Anual"].sum()
```

- Qual a nota média dos alunos nas disciplinas analisadas?

```
mediaRedacao = data["Nota_Redacao"].mean()  
mediaMatematica = data["Nota_Matematica"].mean()
```

Data Science

Quantos alunos ficaram com nota superior a 90 em redação?

```
highRed = data[data["Nota_Redacao"]>90]  
len(highRed)
```

E qual o percentual?

```
len(highRed)/len(estudantes) * 100
```


Data Science

Quantos alunos ficaram com nota superior a 90 em matemática?

```
highMat = data[data["Nota_Matematica"]>90]  
len(highMat)
```

Qual o percentual?

```
len(highMat)/len(estudantes) * 100
```

Data Science



Quantos Alunos tiraram nota maior do que 90 nas duas disciplinas?

```
highBoth = data[(data["Nota_Redacao"]>90) & (data["Nota_Matematica"]>90)]  
len(highBoth)
```

Qual o percentual?

```
len(data[(data["Nota_Redacao"]>90) & (data["Nota_Matematica"]>90)]) / len(estudantes) * 100
```

Carregando dados em xlsx

Data Science

Média de Alunos por Turma da Educação Básica - Ensino Infantil (Creche, Pré-Escola), Ensino Fundamental e Ensino Médio, por Localização e Dependência Administrativa - Brasil, Regiões Geográficas e Unidades da Federação - 2024

<https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/indicadores-educacionais/media-de-alunos-por-turma>

Data Science

Média de Alunos por Turma - Brasil, Regiões Geográficas e Unidades da Federação - 2024

Média de Alunos por Turma da Educação Básica - Ensino Infantil (Creche, Pré-Escola), Ensino Fundamental e Ensino Médio, por Localização e Dependência Administrativa - Brasil, Regiões Geográficas e Unidades da Federação - 2024

Ano	Unidade Geográfica	Localização	Dependência Administrativa	Média de Alunos por Turma / Etapas de Ensino																							
				Educação Infantil			Ensino Fundamental															Ensino Médio					
				Total ¹	Creche	Pré-Escola	Total	Anos Iniciais	Anos Finais	1º Ano	2º ano	3º ano	4º ano	5º ano	6º ano	7º ano	8º ano	9º ano	Turmas Multietapa, Multi ou Correção de Fluxo ²	Total	1ª série	2ª série	3ª série	4ª série	Não-Seriado		
2024	Brasil	Total	Total	15,4	13,7	17,3	22,4	20,9	25,9	19,6	20,2	21,3	21,9	21,9	25,5	26,1	26,0	25,9	13,9	28,9	30,6	28,8	27,5	21,3	21,8		
2024	Brasil	Urbana	Total	15,6	13,6	17,7	23,8	21,7	27,1	20,3	20,8	22,1	22,6	22,8	26,6	27,2	27,2	27,3	16,4	29,6	31,2	29,4	28,2	21,4	23,6		
2024	Brasil	Rural	Total	14,3	14,0	14,5	16,0	15,9	18,5	14,9	15,6	16,2	16,7	16,3	18,8	18,9	18,3	17,8	13,6	21,0	22,8	21,2	19,3	19,9	14,2		
2024	Brasil	Total	Federal	12,3	10,0	14,6	26,0	22,1	28,0	18,6	22,1	23,0	24,1	23,0	27,1	28,2	28,8	27,8	--	30,5	34,3	31,0	28,1	23,3	27,6		
2024	Brasil	Urbana	Federal	12,6	10,3	14,7	26,0	22,1	28,0	18,6	22,1	23,0	24,1	23,0	27,1	28,2	28,8	27,8	--	30,6	34,5	31,2	28,1	23,0	27,4		
2024	Brasil	Rural	Federal	9,3	7,3	13,5	--	--	--	--	--	--	--	--	--	--	--	--	--	30,4	33,3	30,0	27,7	30,3	28,8		
2024	Brasil	Total	Estadual	15,8	10,4	16,4	26,1	22,8	28,1	21,8	22,3	23,0	23,2	23,4	27,5	28,3	28,4	28,4	12,8	29,2	31,0	29,1	27,7	19,9	20,1		
2024	Brasil	Urbana	Estadual	18,3	11,7	18,8	27,4	23,8	29,0	22,9	23,2	24,1	24,2	24,5	28,2	29,1	29,2	29,3	16,4	30,0	31,8	29,9	28,5	20,1	23,5		
2024	Brasil	Rural	Estadual	9,7	9,4	9,7	14,7	12,7	17,3	11,9	12,6	12,9	13,1	13,0	17,3	17,7	17,3	17,1	11,4	20,3	22,1	20,7	18,8	16,9	12,8		
2024	Brasil	Total	Municipal	17,1	15,3	18,7	22,4	22,2	25,3	20,7	21,5	22,5	23,2	23,2	25,4	25,7	25,2	24,8	14,1	26,0	28,2	25,7	24,3	21,3	39,7		
2024	Brasil	Urbana	Municipal	17,6	15,4	19,6	24,6	23,4	27,5	21,8	22,5	23,9	24,4	24,7	27,4	27,9	27,5	27,2	17,8	28,0	30,5	28,0	26,1	21,5	--		
2024	Brasil	Rural	Municipal	14,4	14,1	14,6	16,2	16,2	18,7	15,2	15,9	16,4	17,1	16,6	19,1	19,1	18,6	17,9	13,9	15,8	16,9	14,3	15,1	20,5	39,7		
2024	Brasil	Total	Privada	12,3	11,3	13,7	19,0	17,0	23,0	16,1	16,1	17,4	17,8	17,8	22,6	22,9	23,2	23,5	11,7	26,9	27,6	26,8	26,7	18,5	21,2		
2024	Brasil	Urbana	Privada	12,3	11,3	13,7	19,0	17,0	23,0	16,2	16,1	17,4	17,8	17,8	22,6	22,9	23,2	23,5	11,8	27,0	27,6	26,8	26,8	20,1	21,3		
2024	Brasil	Rural	Privada	14,0	13,5	14,5	17,3	15,4	21,3	14,4	14,6	15,9	16,4	16,2	19,9	21,2	21,8	22,2	10,7	23,6	25,8	24,6	21,5	17,1	6,8		
2024	Brasil	Total	Pública	17,1	15,3	18,7	23,3	22,3	26,6	20,8	21,6	22,6	23,2	23,2	26,3	26,8	26,7	26,5	14,0	29,3	31,1	29,1	27,6	21,5	22,0		
2024	Brasil	Urbana	Pública	17,6	15,4	19,6	25,4	23,5	28,2	22,0	22,6	23,9	24,4	24,7	27,8	28,5	28,4	28,3	17,3	30,0	31,9	29,9	28,4	21,4	24,8		
2024	Brasil	Rural	Pública	14,3	14,0	14,5	16,0	15,9	18,4	14,9	15,6	16,2	16,7	16,3	18,8	18,9	18,3	17,7	13,7	20,9	22,7	21,1	19,2	21,9	14,3		
2024	Norte	Total	Total	17,2	16,2	18,0	21,4	21,4	24,7	20,0	20,7	21,8	22,4	22,3	24,5	24,9	24,5	24,7	14,2	27,5	28,8	27,2	26,3	16,7	13,1		
2024	Norte	Urbana	Total	18,5	16,7	19,5	25,0	22,9	28,4	21,2	21,9	23,4	24,0	24,2	27,9	28,5	28,4	28,8	18,9	31,2	32,1	31,0	30,2	16,1	19,1		
2024	Norte	Rural	Total	13,9	13,5	14,2	15,5	16,2	16,8	15,2	16,1	16,4	17,0	16,5	17,4	17,1	16,3	16,2	14,1	17,2	17,7	18,2	15,8	17,4	10,8		
2024	Norte	Total	Federal	16,0	--	16,0	26,1	21,6	27,9	18,6	19,6	20,4	24,5	24,9	27,1	26,9	29,3	28,3	--	31,8	34,2	31,7	28,9	--	--		
2024	Norte	Urbana	Federal	16,0	--	16,0	26,1	21,6	27,9	18,6	19,6	20,4	24,5	24,9	27,1	26,9	29,3	28,3	--	31,9	34,7	31,8	28,9	--	--		
2024	Norte	Rural	Federal	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	30,7	31,9	31,1	28,7	--	--		
2024	Norte	Total	Estadual	8,8	27,3	7,7	24,3	21,7	26,6	19,2	20,8	22,3	22,8	23,1	26,0	26,8	26,6	27,2	13,1	27,3	28,7	27,1	26,1	16,1	11,1		
2024	Norte	Urbana	Estadual	24,8	27,3	23,6	28,0	25,0	29,3	22,1	23,8	25,8	26,2	26,5	28,6	29,4	29,3	29,7	21,5	31,4	32,3	31,2	30,4	16,1	16,5		

Data Science

O processo de preparar dados para análise é chamado de "data wrangling" e geralmente ocupa a maior parte do tempo de um analista em um projeto de dados. Alguns dos problemas comuns incluem:

Data Science

- Dados ausentes ou valores incorretos/problemas no conjunto de dados;
- Dados formatados de maneira inadequada, impedindo o trabalho adequado do analista;
- Dados distribuídos em vários arquivos ou tabelas;
- Dados no formato incorreto para análise e visualização.

Data Science

```
import pandas as pd
```

```
atu = pd.read_excel("ATU_BRASIL_REGIOES_UFS_2024.xlsx", skiprows=8)
```


Data Science

Temos um problema, todas as colunas estão como object.

Mas qual é o motivo?

```
atu.info()
✓ 0.0s

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 591 entries, 0 to 590
Data columns (total 26 columns):
#   Column                Non-Null Count  Dtype
---  -
0   NU_ANO_CENSO           590 non-null    object
1   UNIDGEO                 588 non-null    object
2   NO_CATEGORIA           588 non-null    object
3   NO_DEPENDENCIA         588 non-null    object
4   ED_INF_CAT_0           588 non-null    object
5   CRE_CAT_0              588 non-null    object
6   PRE_CAT_0              588 non-null    object
7   FUN_CAT_0              588 non-null    object
8   FUN_AI_CAT_0           588 non-null    object
9   FUN_AF_CAT_0           588 non-null    object
10  FUN_01_CAT_0           588 non-null    object
11  FUN_02_CAT_0           588 non-null    object
12  FUN_03_CAT_0           588 non-null    object
13  FUN_04_CAT_0           588 non-null    object
14  FUN_05_CAT_0           588 non-null    object
15  FUN_06_CAT_0           588 non-null    object
16  FUN_07_CAT_0           588 non-null    object
17  FUN_08_CAT_0           588 non-null    object
18  FUN_09_CAT_0           588 non-null    object
19  MULT_ETA_CAT_0         588 non-null    object
...
24  MED_04_CAT_0           588 non-null    object
25  MED_NS_CAT_0           588 non-null    object
dtypes: object(26)
```

Data Science

Vamos buscar as variáveis de interesse antes de buscar uma solução para o problema dos tipos dos atributos.

INEP

Ministério da Educação

Instituto Nacional de Estudos e Pesquisas Educacionais

Anísio Teixeira

Média de Alunos por Turma - Brasil, Regiões Geográficas e Unidades da Federação - 2024

Média de Alunos por Turma da Educação Básica - Ensino Infantil (Creche, Pré-Escola), Ensino Fundamental e Ensino Médio, por Localização e Dependência Administrativa - Brasil, Regiões Geográficas e Unidades da Federação - 2024

Ano	Unidade Geográfica	Localização	Dependência Administrativa	Média de Alunos por Turma / Etapas de Ensino																			
				Educação Infantil			Ensino Fundamental													Ensino Médio			
				Total ¹	Creche	Pré-Escola	Total	Anos Iniciais	Anos Finais	1º Ano	2º ano	3º ano	4º ano	5º ano	6º ano	7º ano	8º ano	9º ano	Turmas Multietapa, Multi ou Correção de Fluxo ²	Total	1ª série	2ª série	3ª série

Data Science

Selecionando as variáveis Unidade Geográfica, Localização, Dependência Administrativa, Total Infantil, Total Fundamental, Total Médio.

Data Science

```
atu = atu.iloc[:, [1,2,3,4,7,20]]
```

```
colunas = ['UG', 'LOC', 'DA', 'TI', 'TF', 'TM' ]  
atu.columns = colunas
```

```
atu
```

Data Science

```
atu.info()
```

✓ 0.0s

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 591 entries, 0 to 590  
Data columns (total 6 columns):  
#   Column  Non-Null Count  Dtype  
---  -  
0    UG      588 non-null    object  
1    LOC     588 non-null    object  
2    DA      588 non-null    object  
3    TI      588 non-null    object  
4    TF      588 non-null    object  
5    TM      588 non-null    object  
dtypes: object(6)  
memory usage: 27.8+ KB
```

Data Science

```
df = atu.replace('--', 0)
df = df.infer_objects(copy=False)
```

```
df.info()
```

✓ 0.0s

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 591 entries, 0 to 590
```

```
Data columns (total 6 columns):
```

#	Column	Non-Null Count	Dtype
0	UG	588 non-null	object
1	LOC	588 non-null	object
2	DA	588 non-null	object
3	TI	588 non-null	float64
4	TF	588 non-null	float64
5	TM	588 non-null	float64

```
dtypes: float64(3), object(3)
```

```
memory usage: 27.8+ KB
```

Data Science

Agrupamentos com groupby()

Média por Unidade Geográfica

```
df.groupby("UG")[["TI", "TF", "TM"]].mean()
```

Média por Localização (Urbana x Rural)

```
df.groupby("LOC")[["TI", "TF", "TM"]].mean()
```

Data Science

Média por Dependência Administrativa

```
df.groupby("DA")[["TI", "TF", "TM"]].mean()
```

Média por combinação de UG e Localização

```
df.groupby(["UG", "LOC"])[["TI", "TF", "TM"]].mean()
```

Total médio por UG e Dependência Administrativa

```
df.groupby(["UG", "DA"])[["TI", "TF", "TM"]].mean()
```


Data Science

Também podemos usar `pivot_table` para análises resumidas:

```
pd.pivot_table(df, values="TF", index="UG", columns="DA", aggfunc="mean")
```

Visualização dos Dados

Data Science



Gráfico de barras (barra horizontal)

Comparar médias por tipo de escola (DA) ou localização (LOC)

```
import matplotlib.pyplot as plt
```

```
df.groupby("DA")[["TI", "TF", "TM"]].mean().plot(kind="barh", figsize=(10, 5))  
plt.title("Média de alunos por Dependência Administrativa")  
plt.xlabel("Quantidade média de matrículas")  
plt.ylabel("Tipo de administração")  
plt.tight_layout()  
plt.show()
```

Data Science

Gráfico de colunas agrupadas

Comparar múltiplas variáveis por categoria

```
df.groupby("LOC")[["TI", "TF", "TM"]].mean().plot(kind="bar", figsize=(8, 5))  
plt.title("Média de matrículas por Localização")  
plt.ylabel("Média de alunos")  
plt.xticks(rotation=0)  
plt.tight_layout()  
plt.show()
```

Data Science

Gráfico de pizza

Distribuição percentual por Dependência Administrativa

```
df.groupby("DA")["TI"].mean().plot.pie(autopct="%1.1f%%", figsize=(6, 6), ylabel="")  
plt.title("Distribuição da Dependência Administrativa para o total Infantil")  
plt.show()
```

Consumindo dados de API's

Data Science



Definição:

O termo API (Interface de Programação de Aplicativos) é bastante comum para o profissional de TI. Uma API permite a integração entre aplicações, enviando e recuperando dados de um servidor. Nesta aula vamos explorar o conceito de API e como utilizá-la com Python, destacando suas vantagens em comparação a arquivos CSV para acesso e uso de dados.


Data Science



Em algumas situações, precisamos de informações específicas que mudam com frequência. Usar uma API permite acessar diretamente os dados necessários, sem baixar arquivos desnecessários, economizando tempo.

A API aparece como uma ponte (em tempo real) entre os dados e nossa aplicação, como mostra a imagem a seguir:

Data Science



Engenharia de Software

Para fazer um primeiro exemplo vamos usar API meios de pagamentos do Governo Federal:

<https://dadosabertos.bcb.gov.br/dataset/estatisticas-meios-pagamentos>

Engenharia de Software

Estatísticas de Meios de Pagamentos



Este conjunto contém diversas estatísticas relacionadas a meios de pagamento. Atualmente está disponibilizado um recurso com informações sobre operações com cartões de pagamento, e outros 2 recursos com diversos instrumentos de pagamentos de varejo utilizados no país.

Estão disponibilizadas estatísticas dos seguintes meios de pagamento:

Instrumentos de periodicidade mensal, com atualização 17 dias após o final do mês de referência:

- Pix (fonte: SPI e documento 1201)
- TED (fonte: CIP-SITRAF e STR)
- Boletos (fonte: CIP-SILOC)
- DOC e TEC (fonte: CIP-SILOC)
- Cheque (fonte: Compe)

Instrumentos de periodicidade trimestral, com atualização 2 meses após o final do trimestre de referência:

- Cartões de crédito, débito e pré-pagos (fonte: documentos 6308 e 6334)
- Pagamentos de convênio, saques, transferências intra-bancárias e débito direto (fonte: documento 6209)



Serão disponibilizadas no futuro novos recursos relacionados a cartões de pagamentos, bem como canais de acesso utilizados em transações financeiras.

Por fim, anualmente são publicadas em uma planilha eletrônica demais estatísticas de meios de pagamentos, acessíveis pelo recurso 'Site do BC - Estatísticas de Meios de Pagamento'.

Engenharia de Software

Dados e recursos



Site do BC - Estatísticas de Meios de Pagamento 🔥

Acesso à página de consulta de Estatísticas de Meios de Pagamentos no site do...

Explorar ▾



Documentação 🔥

Arquivo de documentação do conjunto de dados.

Explorar ▾



API - Documentação Swagger 🔥

Documentação da API utilizando a interface Swagger. Duas versões da interface...

Explorar ▾



API - Navegador de Dados 🔥

Interface de navegação nos dados e construção da URL de chamada para todos os...

Explorar ▾



API - Endpoint OData 🔥

Acesso à API utilizando padrão OData. Open Data Protocol (OData) é um...

Explorar ▾



Estoque e transações de cartões 🔥

Quantidade de cartões emitidos e ativos e transações realizadas com este...

Explorar ▾



Meios de Pagamentos Mensais 🔥

Conjunto de informações sobre operações com boletos bancários e de...

Explorar ▾



Meios de Pagamentos Trimestrais 🔥

Conjunto de informações sobre operações com cartões de pagamento e de...

Explorar ▾

Engenharia de Software

 > Organizações > BCB/Decem > Estatísticas de Meios de ... > API - Navegador de Dados

API - Navegador de Dados

 Ir para recurso

URL: https://olinda.bcb.gov.br/olinda/servico/MPV_DadosAbertos/versao/v1/aplicacao#!/

Interface de navegação nos dados e construção da URL de chamada para todos os recursos da API.

Endereço padrão:

[https://olinda.bcb.gov.br/olinda/servico/MPV_DadosAbertos/versao/v1/odata/\[codigo_recurso\]?\\$format=json&\[Outros Parâmetros\]](https://olinda.bcb.gov.br/olinda/servico/MPV_DadosAbertos/versao/v1/odata/[codigo_recurso]?$format=json&[Outros Parâmetros])

Os parâmetros disponíveis podem ser visualizados na [documentação](#)

Os códigos dos recursos disponibilizados são:

Quantidadeetransacoesdecartoes MeiosdePagamentosMensalDA MeiosdePagamentosTrimestralDA



Formatos de Retorno:

Por padrão os dados podem ser retornados em 4 formatos:

- json (Padrão)
- xml
- text/csv
- text/html

Não há visões criadas para este recurso ainda.

Engenharia de Software

Estatísticas de Meios de Pagamento - v1

Recursos

Título	Descrição
Estoque e transações de cartões	Quantidade de cartões emitidos e ativos e transações realizadas com este instrumento de pagamento.
Meios de Pagamentos Mensais	Conjunto de informações sobre operações com boletos bancários e de transferências de crédito. Dados ficam disponíveis a partir do 17º dia do mês subsequente.
Meios de Pagamentos Trimestrais	Conjunto de informações sobre operações com cartões de pagamento e de transferências de crédito (boletos bancários, cartões de crédito e débito, transferências bancárias). Dados ficam disponíveis 90 dias após o final do trimestre.

Criado por Banco Central do Brasil

Engenharia de Software

Essa API do governo oferece uma interface para facilitar a geração de url's

* Trimestre ⓘ Exemplo: 20221

Máximo ⓘ 100

Filtro ⓘ Exemplo: Nome eq 'João'

Ordenação ⓘ Exemplo: Nome asc, Idade desc

Saída ⓘ json

Campos

☐ Trimestre ⓘ	trimestre
☐ Bandeira do cartão ⓘ	nomeBandeira
☐ Função do cartão ⓘ	nomeFuncao
☐ Produto do cartão ⓘ	produto
☐ Quantidade de cartões emitidos ⓘ	qtdCartoesEmitidos
☐ Quantidade de cartões ativos ⓘ	qtdCartoesAtivos

URL de pesquisa

`https://olinda.bcb.gov.br/olinda/servico/MPV_DadosAbertos/versao/v1/odata/Quantidadeetransacoesdecartoes(trimestre=@trimestre)?@trimestre="&$top=100&$format=json`

Copiar URL Baixar json Executar

Data Science

Tabela	Pivot	JSON							
Trimestre	Bandeira do cartão	Função do cartão	Produto do cartão	Quantidade de car.	Quantidade de car.	Quantidade de tra.	Va		
20231	American Express	Crédito	Intermediário	433549	335542	9107357	161798		

Mudando para 1000 resultados:

 Trimestre

 Máximo

 Filtro

Engenharia de Software

Vamos criar uma função para acessar a url:

```
import pandas as pd
import requests
import json

def requisicao_api(link):
    resposta = requests.get(link)
    if resposta.status_code == 200:
        dados = resposta.json()
        print('Status Code:', resposta.status_code)
    else:
        print('Status Code:', resposta.status_code)
```

Engenharia de Software

Para executar a função devemos chamá-la `requisicao_api` e passar a url fornecida pelo site do governo:

```
requisicao_api(url)
```

Engenharia de Software

Temos um problema, nossa função só está checando a url, não estamos salvando os dados em nenhum lugar. Para resolver esse problema devemos inserir o código a seguir após a confirmação do status code 200:

Engenharia de Software

```
with open('resultado.json', 'w', encoding='utf-8') as arquivo:  
    json.dump(dados, arquivo, ensure_ascii=False, indent=4)
```

Engenharia de Software

Que supimpa! Temos um Json, mas temos que converter em um DataFrame do pandas para usar as técnicas que estamos aprendendo em Data Science:

Engenharia de Software

```
jsondata =  
pd.read_json('resultado.json')  
data = jsondata['value']  
  
df = pd.json_normalize(data)
```

Dúvidas?





Marco Mialaret, MSc

Telefone:

81 98160 7018

E-mail:

marcomialaret@gmail.com

